

$$AV = \begin{pmatrix} 0 & 0 & \sqrt{2} \\ 0 & \frac{1}{6} & 0 \end{pmatrix} = U \Sigma = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \cdot \Sigma \Rightarrow \Sigma = \begin{pmatrix} 0 & \sqrt{2} & 0 \\ \sqrt{2} & 0 & 0 \end{pmatrix}$$

$$b_{k+1} = \frac{C_0 b_k}{\|C_0 b_k\|} = \frac{C_0^2 b_{k-1}}{\|C_0^2 b_{k-1}\|} = \dots = \frac{C_0^{k+1} b_0}{\|C_0^{k+1} b_0\|} \Rightarrow b_k = \frac{C_0^k b_0}{\|C_0^k b_0\|}$$

הפעולה C_0 היא פרויקציה לאורך V וקרינה לאורך V^\perp . λ הוא הערך העigen של C_0 ב- V .

$$C_0^k = V \lambda^k V^{-1} \leftarrow C_0 = V \lambda V^{-1}$$

$$b_k = \frac{V \lambda^k V^{-1} (\sum_{i=1}^n a_i v_i)}{\|V \lambda^k V^{-1} (\sum_{i=1}^n a_i v_i)\|} = \frac{\sum_{i=1}^n a_i \lambda^k v_i}{\|\sum_{i=1}^n a_i \lambda^k v_i\|} = \frac{a_1 \lambda_1^k (V_1 + \frac{a_2}{a_1} (\frac{\lambda_2}{\lambda_1})^k V_2 + \dots)}{\|a_1 \lambda_1^k (V_1 + \frac{a_2}{a_1} (\frac{\lambda_2}{\lambda_1})^k V_2 + \dots)\|}$$

$$= \frac{a_1 \lambda_1^k}{\|a_1 \lambda_1^k\|} \cdot \frac{V_1 + \frac{a_2}{a_1} (\frac{\lambda_2}{\lambda_1})^k V_2 + \dots}{\|V_1 + \frac{a_2}{a_1} (\frac{\lambda_2}{\lambda_1})^k V_2 + \dots\|} \xrightarrow{k \rightarrow \infty} \frac{a_1 \lambda_1^k}{\|a_1 \lambda_1^k\|} \cdot \frac{V_1}{\|V_1\|} = \pm 1 \cdot \frac{V_1}{\|V_1\|} = \pm V_1$$

מכאן V_1 היא ה-eigenvector.

$$f(\sigma) = U \text{diag}(\sigma) U^T \vec{x} = (\sum_{i=1}^n u_i \sigma_i u_i^T) \vec{x}$$

$$\Rightarrow \frac{\partial f_j}{\partial \sigma_i} = (u_i u_i^T \vec{x})_j \rightarrow j\text{-הרכיב}$$

הקואורנטים של K -ה וקטור \vec{x} הם $\langle u_i, \vec{x} \rangle u_i$.

$$h(\sigma) = \frac{1}{2} \|f(\sigma) - \gamma\|^2 \quad \nabla_\sigma (h \circ f) = J_\sigma (h \circ f)^T$$

$$J_\sigma (h \circ f) = J_{f(\sigma)}(h) \cdot J_\sigma(f)$$

$$J_{f(\sigma)}(h) = (f(\sigma) - \gamma)$$

$$\Rightarrow \nabla_\sigma (h \circ f) = (f(\sigma) - \gamma)^T \cdot \nabla_\sigma(f)$$

$$S_j(x) = \frac{e^{x_j}}{\sum_{i=1}^n e^{x_i}}$$

$$\frac{\partial S_j}{\partial x_i} = \frac{\frac{\partial e^{x_j}}{\partial x_i} \cdot \sum_{k=1}^n e^{x_k} - \frac{\partial \sum_{k=1}^n e^{x_k}}{\partial x_i} \cdot e^{x_j}}{(\sum_{k=1}^n e^{x_k})^2} = \begin{cases} -e^{x_i} e^{x_j} / (\sum_{k=1}^n e^{x_k})^2 & i \neq j \\ \frac{e^{x_i} \cdot \sum_{k=1}^n e^{x_k} - e^{x_i}}{(\sum_{k=1}^n e^{x_k})^2} & i = j \end{cases}$$

$$\frac{\partial S_j}{\partial x_i} = \begin{cases} -S_i \cdot S_j & i \neq j \\ S_j(1 - S_j) & i = j \end{cases}$$

הכאן S_i היא ההסתברות של x_i .

$$f(x, y) = x^3 - 5xy - y^5 \rightarrow \nabla f = \begin{pmatrix} 3x^2 - 5y \\ -5y^4 - 5x \end{pmatrix} \quad (7)$$

$$\rightarrow H(f) = \begin{pmatrix} 6x & -5 \\ -5 & -20y^4 \end{pmatrix}$$

$$\hat{U}_n = \frac{1}{n} \sum_{i=1}^n X_i \quad E[\hat{U}_n] = \frac{1}{n} E[\sum X_i] = \frac{1}{n} \sum E[X_i] = \mu \quad (8)$$

$$P(|\hat{U}_n - \mu| \geq \varepsilon) \leq \frac{E[|\hat{U}_n - \mu|^2]}{\varepsilon^2} \quad \text{Chebyshev's inequality}$$

$$\text{Var}(|\hat{U}_n - \mu|) = E[|\hat{U}_n - \mu|^2] - E^2[|\hat{U}_n - \mu|] \geq 0$$

$$\Rightarrow E[|\hat{U}_n - \mu|^2] \leq E[|\hat{U}_n - \mu|^2] = E[(\hat{U}_n - \mu)^2] = E[(\hat{U}_n - E[\hat{U}_n])^2] = \text{Var}(\hat{U}_n)$$

$$= \text{Var}\left(\frac{1}{n} \sum X_i\right) = \frac{1}{n^2} \cdot n \sigma^2 = \frac{\sigma^2}{n}$$

$$\Rightarrow E[|\hat{U}_n - \mu|] \leq \frac{\sigma}{\sqrt{n}} \rightarrow 0 \leq P(|\hat{U}_n - \mu| \geq \varepsilon) \leq \frac{\sigma}{\varepsilon \sqrt{n}}$$

$$\Rightarrow \lim_{n \rightarrow \infty} P(|\hat{U}_n - \mu| > \varepsilon) \leq \lim_{n \rightarrow \infty} \left(\frac{\sigma}{\varepsilon \sqrt{n}} \right) = 0$$

$$\Rightarrow \lim_{n \rightarrow \infty} (P(|\hat{U}_n - \mu| \geq \varepsilon)) = 0 \quad \square$$

$$\mathcal{L}(\theta | \bar{x}_i) = f_e(\bar{x}_i) = \frac{1}{(2\pi)^d |Z|} \cdot e^{-\frac{1}{2} \cdot (\bar{x}_i - \bar{\mu})^T \Sigma^{-1} \cdot (\bar{x}_i - \bar{\mu})} \quad (9)$$

$$\Rightarrow \mathcal{L}(\theta | x_1, \dots, x_m) = \prod_{i=1}^m \frac{1}{(2\pi)^d |Z|} \cdot e^{-\frac{1}{2} (\bar{x}_i - \bar{\mu})^T \Sigma^{-1} (\bar{x}_i - \bar{\mu})} = \left[\frac{1}{(2\pi)^d |Z|} \right]^m \cdot e^{-\frac{1}{2} \sum_{i=1}^m (\bar{x}_i - \bar{\mu})^T \Sigma^{-1} (\bar{x}_i - \bar{\mu})}$$

$$\log(\mathcal{L}) = \log \left[\left(\frac{1}{(2\pi)^d |Z|} \right)^m \cdot e^{-\frac{1}{2} \sum_{i=1}^m (\bar{x}_i - \bar{\mu})^T \Sigma^{-1} (\bar{x}_i - \bar{\mu})} \right]$$

$$= \log \left[\left((2\pi)^d |Z| \right)^{-m} \right] + \left(-\frac{1}{2} \sum_{i=1}^m (\bar{x}_i - \bar{\mu})^T \Sigma^{-1} (\bar{x}_i - \bar{\mu}) \right)$$

$$= -m \cdot \log((2\pi)^d |Z|) - \frac{1}{2} \sum_{i=1}^m (\bar{x}_i - \bar{\mu})^T \Sigma^{-1} (\bar{x}_i - \bar{\mu})$$

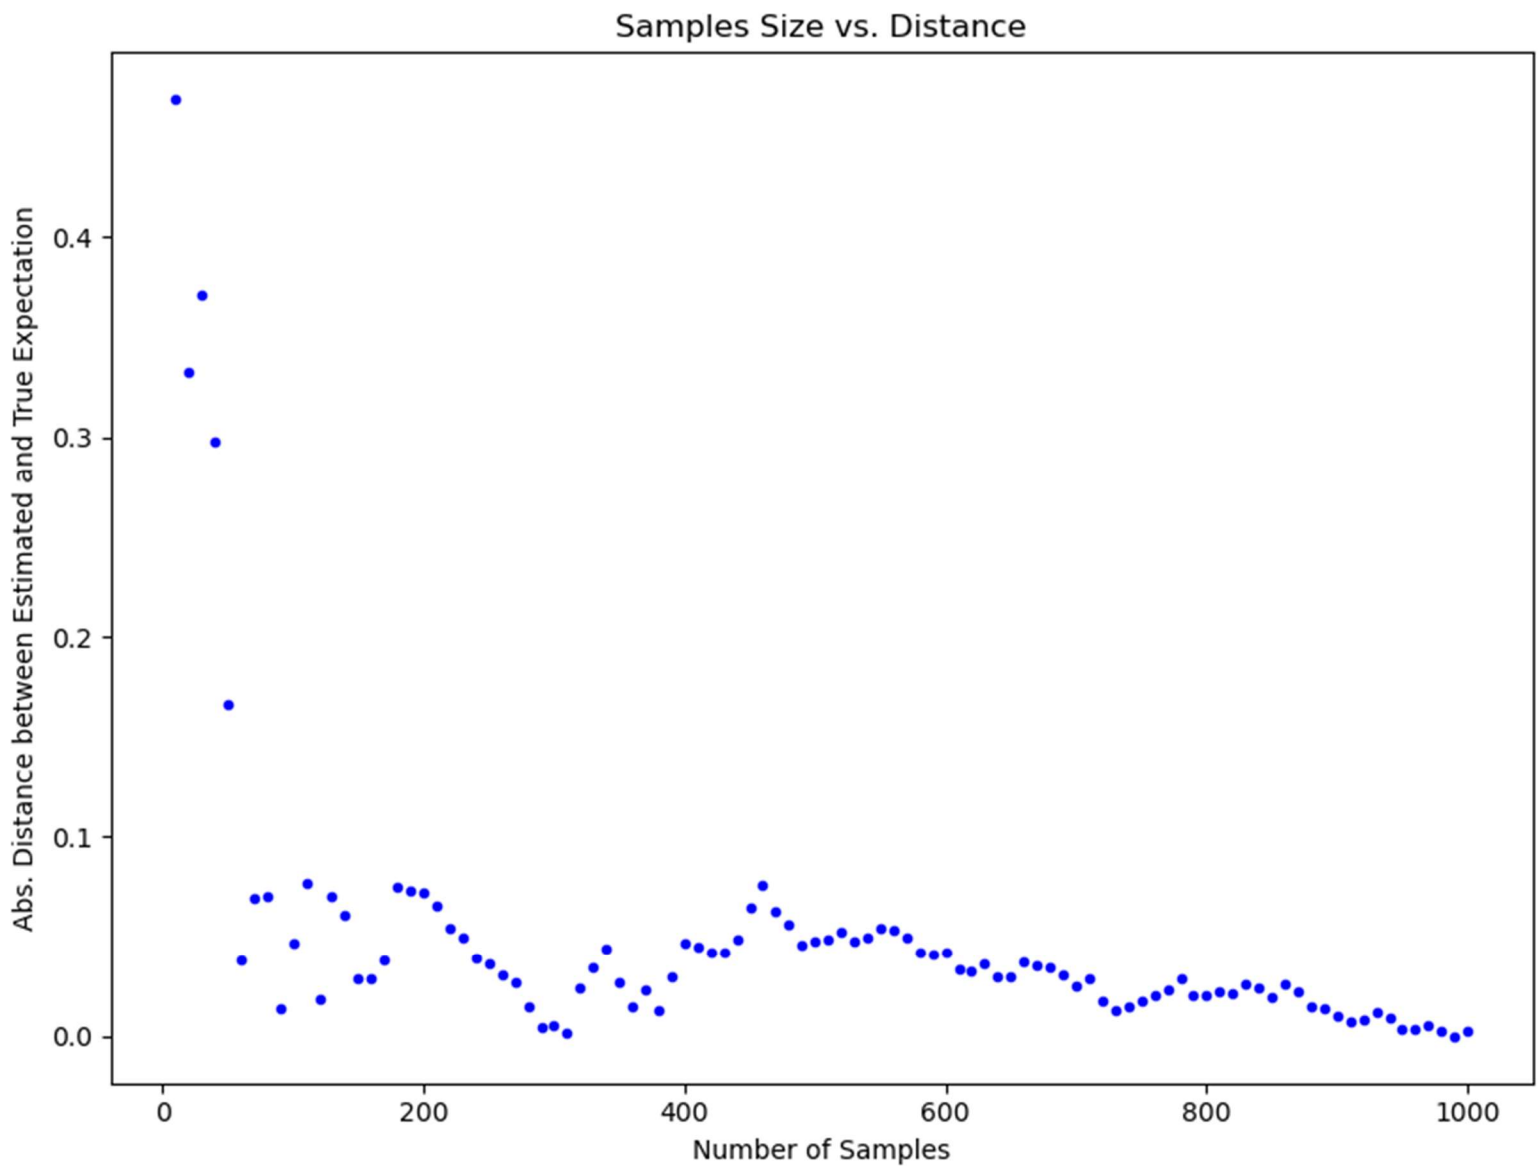
$$= -m d \log(2\pi) - m \log |Z| - \frac{1}{2} \sum_{i=1}^m (\bar{x}_i - \bar{\mu})^T \cdot \Sigma^{-1} (\bar{x}_i - \bar{\mu})$$

חלק מעשי


(1) תוחלת ושונות שהותאמו (רלוונטי להרצה ספציפית)

(1.087897120940502 ,9.997053997632051)

(2) גרף שהתקבל עבור התאמות שונות:



(3) דגמנו משתנים ממרחב עם התפלגות גאוסיאנית ולכן נצפה שפונקציית הצפיפות תיראה כמו פעמון גאוס – מקבלת ערכים גבוהים סביב התוחלת וברוחב המתאים לשונות. הגרף שהתקבל:



(4) תוחלת:

[0.0079784 4.00620038 0.03455066- 0.008687-]

שונות משותפת:

[0.46758105 0.0233973- 0.12987336 0.92618336]]

[0.07496864- 0.0417188- 1.85799249 0.12987336]

[0.01623343 1.03177586 0.0417188- 0.0233973-]


[[0.97866918 0.01623343 0.07496864- 0.46758105]

(5) נצפה שאזורים עם ערכי f_1 , f_3 עם סבירות (Likelihood) גבוהה יותר יהיו "חמים" יותר,

דהיינו סביב $f_1=0$, $f_3=4$ (הערכים האמיתיים) נצפה לראות צבעים חמים וככל

שמתרחקים מהערכים האלה הצבעים יתקררו. גרף:

Log-Likelihood by f_1 , f_3



f1: -0.05 , f3: 3.97 (6